### 配置化任务开发框架 dataConnector 功能简介

#### data-connector

基于 spark,用于连接不同异构数据源,通过可配置的、兼容 sql 语法的形式实现多数据源的组合、转换并持久化到不同存储介质。

#### 主要亮点

不用写代码即可实现任务输出 可替代数据开发角色 逻辑简单明了 入门门槛低

# 使用场景

目前主要定位日常周期性的任务统计和常规 ETL 任务开发等。

# 主要算子

dataSource, dataJoin, dataGroup, dataCollect, dataMap 操作结果都表示数据源,其中 dataSource 是初始数据源。

dataSource: 从存储介质加载数据源并生成临时表。可支持的数据源有 hdfs,关系数据库,hive 表等。

select eventide,userId ad pushUserId,siteId,linkId,timestamp as pushTime,params['pos'] as pos, ,params['msgId'] as msgId ,params['sourceUuid'] as sourceUuid' from push where eventId in ('e-8','e-12','e-14','e-16','e-18','e-20','e-22') and msgId is not null

dataJoin: 实现两个表的连接,包括 inner, outer, cross join 等。

```
⟨yueducdataJoin id="push_receive" joinType="LEF1 OUTER JOHN" leftRef="push" rightRef="receive"
filter="push, magide-receive, magid and push, pos=receive, pos and ((push, sourceUtid is null and receive, sourceUtid is null) or (push, sourceUtide-receive, sourceUtid))">
⟨yueduccolum expr="push, "/>
⟨yueducolum expr="receive, userId" alias="receiveUserId"/>
⟨yueducdum expr="receive, userId" alias="receiveUserId"/>
⟨/yueducdum expr="receive, userId" alias="receiveUserId"/>
⟨/yueducdum expr="receive, userId" alias="receiveUserId"/>
```

select push.\*,receive.userld as receiveUserld from push left outer join receive on push.msgld=receive.msgld and push.pos=receive.pos and push.sourceUuid=receive.sourceUuid

# dataGroup:在现有表数据基础上实现分组统计

select count(receiveUserId) as receiveCount, count(distinct receiveUserId) as receiveUserCount, count(pushUserId) as pushCount, count(distinct pushUserId) as pushUserCount,siteId,eventId,pos from push\_receive group by siteId,eventId,pos

## dataMap:在现有数据源基础上进行选择字段域的变换等

select userld, siteld, source Uuid,

case when registerDate=readDate then 1 else 2 end as readUserTag, case when registerDate=readDate and rank=1 then 3 else 4 end as accessUserTag from ext\_read\_user

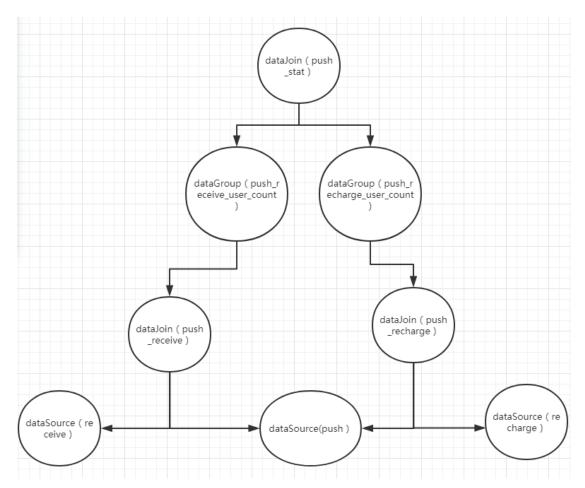
dataCollect:实现两个数据表的 union, INTERSECT, except 等。

select userId,siteId, sourceUuid,price1,price2,date,vipReadRecord,rank from trade UNION select userId,siteId, sourceUuid,price1,price2,date,vipReadRecord,rank from simple\_vip\_read

# 配置了 savePath 或者 jdbcUrl 的数据源结果将会被持久化,例如

### 算子组合

dataJoin 和 dataCollect 是两元操作算子,分别用 leftRef 和 rightRef 指示左右数据源,dataGroup,dataMap 是一元操作算子,分别用 target 指示操作对象 dataSource 是原子数据源,被其他操作算子指定,位于依赖树的叶子节点。 依赖树示例:



#### 开发指南

TaskProcessor 是 main class,支持 gnu like 的参数形式,主要的参数 config 和 hdfs,如果 hdfs 选项指定了,就表示配置文件使用的 hdfs 路径,否则代表本地文件路径。

本框架基于猛犸调度,只需要上传该项目 jar 包,指定配置文件路径即可。对于日常开发,可以随时修改并且上传配置文件然后调度即可,如下命令:

bin/hadoop fs -put -f push\_translation.xml /user/pris/conf

# 功能完善

- 1. dataMap 和 dataGroup target 属性支持多表,达到支持多表的隐式连接功能
- 2. sql 自动翻译为配置文件,减少人工编辑负担。